

Implementación de RAG en Robot Autónomo Controlado por LLM y Análisis de Desempeño y Aprendizaje en Entornos Reales

Eduardo Ariño Pelegrín

Universidad Politécnica de Madrid, España


Motivación

- Robótica

- **Necesita:** Solución a problema *long tail*.
- **Provee:** Interfaces y controladores para interactuar con el mundo físico.

- Modelos de lenguaje


- **Proveen:** Mayor capacidad de generalización.
- **Necesitan:** En transición hacia *agentic AI*, retroalimentación del mundo físico.




- Revisión de la literatura (SOTA).
 - Modelos de lenguaje, visión-lenguaje, visión-lenguaje-acción, etc.
- Diseño de robot.
 - **ESP32-WROVER** y **Arduino** (para enviar y recibir audio y comandos)
- Integración de modelo como controlador bajo *framework* propio.
 - **Entrada y salida** de/hacia el mundo.
 - **Módulos auxiliares**: Rectificación, Reconocimiento de cara, etc.
 - ...
- Estudio de desempeño y aprendizaje en conducción y matemáticas (*proxy* de conocimiento general).
 - ¿Puede un modelo controlar de forma **autónoma** interfaces físicas y virtuales (bajo este *framework*)? ¿Puntos de fallo?
 - ¿Mejora con **SFT**? ¿*Trade-offs*?
 - ¿Utilizan sus **recuerdos**? ¿Cómo?

(1) LM

- Auto-supervisado
- Auto-regresivo en inferencia



(2) VLM



ViT



CLIP-ViT SigLIP

*Text
encoder*

*Image
encoder*

MLP

*Text decoder
(generativo)*

(3) VLA

- Visión-lenguaje (transición)
 - Planificadores de tareas
 - Necesitan controlador de bajo nivel
 - Ejemplo: PaLM-E
- Visión-lenguaje-acción
 - *action expert decoder (flow-matching)*
 - Generan *action chunks*
 - Ejemplo: π_0

(4) Razonamiento

In-context learning
(modelos mejoran con
ejemplos/*few-shot*)



Prompting

(CoT) ↙

Thinking tokens

↘ (PAL)

Tool use

(5) RAG

Sparse


- basados en frecuencia
- Ejemplos: TF-IDF, BM25

Dense

- basados en *encoders*
- Ejemplos: CoBERT, SBERT

Hybrid


- mix





Metodología: Decisiones de diseño bajo un caso de uso

input vision, recognizedPeople, datetime, audio, longTermMemories, webBrowsingResult

output internalThinking, functionCalling (web_browse), bodyControl (speak), currentTask, primaryGoal




Desarrollo: Cuerpo de robot



Desarrollo: Resumen de funcionamiento

- Audio de KY-037, INMP441, ESP32-WROVER → Ordenador
- Imágenes de ESP32-CAM → Ordenador
- Obtención de recuerdos (sobre cara, audio, tarea, o bajo demanda)
- Qwen3-VL (remote/Modal)
- Parseo de comandos (ordenador) → ESP32-WROVER → MAX98357A / Arduino → L298N → motores
- Parseo de funciones (ordenador) → ejecución (bloqueante)



Resultados y conclusiones

- Modelos **más grandes** se adaptan mejor
- SFT mejora**, pero **riesgo CF**
- Dataset de **difícil** creación sintética
- Uso** de recuerdos, pero **no** auto-aprendizaje
- Sin retroalimentación, **malos hábitos**

Tipo de comportamiento	Versión modelo (sobre Qwen3-VL-Instruct)	Aciertos por vuelta	Accuracy	Tiempo (segundos)
Robot (vía <i>system prompt</i>)	2B	Vuelta 1: 5/47	3,5%	-
		Vuelta 2: 0/47		
		Vuelta 3: 0/47		
	4B	Vuelta 1: 0/47	24,1%	-
		Vuelta 2: 14/47		
		Vuelta 3: 20/47		
	8B	Vuelta 1: 26/47	53,9%	1441,53
		Vuelta 2: 25/47		
		Vuelta 3: 25/47		
	32B	Vuelta 1: 25/47	54,6%	4910,77
		Vuelta 2: 27/47		
		Vuelta 3: 25/47		
Robot (vía <i>system prompt</i> y SFT con dataset propio)	2B-Robot-SFT	Vuelta 1: 37/47	76,6%	681,11
		Vuelta 2: 36/47		
		Vuelta 3: 35/47		

Tipo de comportamiento	Versión modelo (sobre Qwen3-VL-Instruct)	Accuracy	Segundos turnos utilizados	Tiempo (segundos)
Asistente	2B	60,7% (alto uso de <code>execute_code</code> incorrectamente)	748/1319	9216,07
	4B	93,5%	26/1319	8274,93
	8B	94,7%	22/1319	7278,27
	32B	96,1%	8/1319	12941,32
Robot (vía <i>system prompt</i>)	2B	0,45% (proyectado por pérdida de formato en "speak" tras pregunta 30)	1289/1319 (proyectado por pérdida de formato en "speak" tras pregunta 30)	-
		20% (hasta pregunta 30 donde pierde formato)	0/30 (hasta pregunta 30 donde pierde formato)	-
	4B	17,36% (proyectado por pérdida de formato en "speak" tras pregunta 255)	1169/1319 (proyectado por pérdida de formato en "speak" tras pregunta 255)	-
		89,8% (hasta pregunta 255 donde pierde formato)	9/255 (hasta pregunta 255 donde pierde formato)	-
	8B	3,2% (pérdida de formato en "speak" tras pregunta 48 hasta 1319)	1317/1319 (pérdida de formato en "speak" tras pregunta 48 hasta 1319)	35238,77
		87,5% (hasta pregunta 48 donde pierde formato)	46/48 (hasta pregunta 48 donde pierde formato)	-
	32B	1,9% (proyectado por pérdida de formato en "speak" tras pregunta 27)	1294/1319 (proyectado por pérdida de formato en "speak")	-
		92,6% (hasta pregunta 27 donde pierde formato)	1/27 (hasta pregunta 27 donde pierde formato)	-
Robot (vía <i>system prompt</i> y SFT con dataset propio)	2B-Robot-SFT	21,4% (proyectado por pérdida de formato en "speak" en más de 200 turnos, de 633 a 874, antes de abortar la evaluación)	882/1319 (proyectado por pérdida de formato en "speak")	-
		58,2% (hasta pregunta 55 antes de perder formato por primera vez)	0/55 (hasta pregunta 55 antes de perder formato por primera vez)	-
		44,5% (hasta pregunta 633 donde pierde definitivamente formato)	196/633 (hasta pregunta donde pierde definitivamente formato)	-

• Software

- **SFT:** (1) *Token weighing*, (2) 2 fases (vision+MLP+lenguaje, lenguaje), (3) portar *datasets* a *framework*
- **Entrada sensorial:** audio e imágenes secuenciales → captura continua
- **Arquitectura:** Cross-attention, action expert, omni, paralelización salida (pensamiento interno, movimiento cuerpo, habla, etc.)

• Hardware

- **Visión:** 2 cámaras incrustadas → 1 cámara de mayor calidad
- **Movimiento:** 2 ruedas (2 motores) + rueda loca → 4 ruedas (4 motores)
- **Audio:** Mejor micrófono para evitar necesidad de enunciación/alto volumen

